

Plano de Melhoria — TCC

Sistema de Detecção de Intrusão Ciber-Físico para UAVs

Análise aprofundada: o que foi feito, o que está bom, o que precisa melhorar e o que falta

Caio de Souza Lima — UFF | 18 de maio de 2026

Resumo Executivo

Este documento consolida uma análise completa do estado atual do TCC com base na leitura do README, de todos os notebooks, documentos de apoio (docs/) e rascunho ABNT. O trabalho está em estágio avançado: os dois ramos do IDS híbrido (ciber e físico) foram implementados, avaliados e já possuem um rascunho de monografia praticamente completo. Os pontos de melhoria são bem definidos e alcançáveis antes da defesa.

Quadro Geral de Status por Área

Área / Componente	Status	Observação
Ramo Ciber (Dataset T-ITS)	Implementado e avaliado	LSTM + RF, split temporal, 7 features, resultados documentados
Ramo Físico (PX4-QUAD-SITL)	Implementado e avaliado	4 notebooks, merge_asof, 11 features derivadas, LSTM + RF, resultados documentados
Rascunho ABNT da monografia	Muito avançado	Cap. 1–7 escritos, tabelas de resultados preenchidas, referências parcialmente completas
Documentação de apoio (docs/)	Muito detalhada	resumo.md, objetivos-alcancados-limitacoes.md, DOCUMENTO.md em cada pasta
Baseline (Random Forest)	Implementado	Comparação LSTM vs RF em ambos os ramos com F1-macro
MAVLink Sequence Dataset	Não utilizado	Previsto no README mas sem notebook nem análise até o momento
FDI (False Data Injection)	Apenas teórico	Sem dataset com rótulo FDI — tratado só no referencial teórico
Ablação de tamanho de janela	Código pronto, não rodado	RUN_WINDOW_ABLATION = False no notebook ciber
Figura 1 (diagrama arquitetura)	Faltando	Rascunho ABNT tem [INSERIR FIGURA 1] — não foi criada
Fusão decisória dos dois ramos	Trabalho futuro	Descrita como objetivo, mas não implementada — corretamente declarada como limitação
IDS em tempo real (latência)	Não medido	Pipeline offline sobre CSV; latência de inferência não foi calculada

1. O Que Já Está Feito

Esta seção detalha tudo o que foi implementado e documentado, servindo como registro do avanço real do trabalho.

1.1 Ramo Ciber — Dataset T-ITS

Etapa	Detalhe
Carregamento e inspeção	54.783 linhas, 38 colunas lidas com pandas. <code>df.info()</code> , <code>value_counts()</code> , estatísticas por classe.
Limpeza dos dados	Conversão numérica de 7 colunas base com <code>pd.to_numeric(errors='coerce')</code> ; imputação pela mediana nas colunas estendidas; remoção de NaN nas colunas base e em 'class'.
Análise exploratória (EDA)	Estatísticas por classe (média, std, min, max) para <code>frame.len</code> , <code>ip.len</code> , <code>data.len</code> , <code>time_since_last_packet</code> . Inspeção Replay vs DoS com cobertura por camada, Mann-Whitney U, boxplots em escala log.
Feature engineering	FEATS_V2: 7 features (<code>frame.len</code> , <code>ip.len</code> , <code>time_since_last_packet</code> , <code>wlan.fc.type</code> , <code>wlan.duration</code> , <code>udp.length</code> , <code>data.len</code>).
Janelas deslizantes	<code>window=10</code> timesteps, ordenação por <code>timestamp_c</code> , 33.092 amostras no formato (10, 7).
Split temporal	80/20 por classe, ordenado por <code>timestamp_c</code> — evita vazamento temporal. Validação nos últimos 10% do treino (não aleatório).
Normalização	<code>MinMaxScaler</code> ajustado só no treino e aplicado ao teste — sem vazamento de escala.
Modelo LSTM	<code>Input(10,7) → LSTM(50) → Dropout(0.2) → Dense(3, softmax)</code> . <code>EarlyStopping(patience=5)</code> + <code>ModelCheckpoint</code> . Até 100 épocas.
Baseline RF	<code>RandomForestClassifier(n_estimators=200)</code> treinado sobre janelas achatadas (N, 70 features).
Métricas	<code>classification_report</code> (precision, recall, F1 por classe), F1-macro, matriz de confusão visual.
Artefatos salvos	<code>best_model_cyber.keras</code> , <code>confusion_matrix_cyber.png</code> , <code>learning_curves_amo_ciber.png</code> .
Resultados obtidos	LSTM F1-macro = 0,652 RF F1-macro = 0,663. Benign F1 > 0,85. DoS recall alto na LSTM (0,829). Replay: principal fragilidade (LSTM F1=0,409, RF F1=0,542).

1.2 Ramo Físico — UAVAttackData PX4-QUAD-SITL

Etapa	Detalhe
4 notebooks distintos	<code>Infos_gps_position.ipynb</code> , <code>Infos_local_position.ipynb</code> , <code>Infos_fusao_gps_local_ekf.ipynb</code> , <code>Infos_lstm_fusao_px4.ipynb</code> — cada um com foco crescente de exploração a modelo.
Fusão temporal (<code>merge_asof</code>)	Alinhamento de <code>vehicle_local_position</code> + <code>vehicle_gps_position</code> + <code>ekf2_innovations</code> pelo <code>timestamp</code> com <code>direction='backward'</code> . 44.957 linhas × 113 colunas.

Etapa	Detalhe
Features derivadas	innov_norm: norma L2 das inovações do EKF. dv_xy: discrepância de velocidade horizontal GPS vs local. r_xy: deriva horizontal acumulada desde o início do voo (principal separador de GPS Spoofing).
Conjunto final de features	11 variáveis: x, y, z, vx, vy, vz, eph_loc, eph_gps, innov_norm, dv_xy, r_xy.
Janelas deslizantes	WINDOW=40 timesteps. Split temporal 80/20 dentro de cada voo (por condição). Treino: 35.845 janelas, Teste: 8.872 janelas.
Normalização	StandardScaler ajustado só no treino.
Modelo LSTM	Input(40,11) → LSTM(48) → Dropout(0,25) → Dense(3, softmax). EarlyStopping(patience=5, restore_best_weights=True). Semente fixada em 42.
Baseline RF	RandomForestClassifier(n_estimators=200) com janelas achatadas (N, 440 features).
Artefatos salvos	best_model_px4.keras, confusion_matrix_px4.png, learning_curves_amo_fisico.png.
Resultados obtidos	LSTM F1-macro = 0,549 RF F1-macro = 0,674. GPS Spoofing detectado com recall moderado (LSTM 0,744). Ping DoS: classe mais fraca (LSTM recall 0,166). RF superou LSTM significativamente.

1.3 Rascunho ABNT da Monografia

Capítulo	Conteúdo
Capítulo 1 — Introdução	Contextualização, problema, motivação, objetivos gerais e específicos, organização do trabalho. Com citações ABNT.
Capítulo 2 — Referencial Teórico	CPS e UAVs, vetores de ataque (DoS, Replay, GPS Spoofing, FDI), IDS baseado em ML, LSTM, datasets públicos.
Capítulo 3 — Metodologia	Arquitetura do IDS híbrido, ramo ciber (seções 3.2.1 a 3.2.4), ramo físico (seções 3.3.1 a 3.3.4), protocolo de avaliação. Tabelas de features, volumes de dados, distribuição de classes.
Capítulo 4 — Resultados	Tabela 5 (LSTM vs RF ramo ciber) e Tabela 6 (LSTM vs RF ramo físico) preenchidas com números reais. Referências às figuras das curvas e matrizes.
Capítulo 5 — Discussão	Desempenho comparativo, dificuldades por classe, complementaridade dos dois ramos.
Capítulo 6 — Limitações	Escassez de voos, vazamento temporal residual, protótipo offline, híbrido sem fusão temporal, ausência de FDI.
Capítulo 7 — Conclusão	Síntese dos dois ramos, resultados finais, limitações declaradas, trabalhos futuros.
Referências	4 referências principais em formato ABNT. Algumas com data de acesso a preencher.

1.4 Documentação de Apoio

Arquivo	Conteúdo
docs/resumo.md	Análise detalhada do dataset T-ITS: EDA, modelagem, argumentação para o texto da monografia, plano de estudo do UAVAttackData.
docs/objetivos-alcancados-limitacoes.md	Alinhamento entre os objetivos do README e o estado atual do trabalho. Frases prontas para conclusão e lista de trabalhos futuros.
notebooks/.../DOCUMENTO.md	Documentação por pasta de análise: o que o notebook faz, resultados, limitações e perguntas típicas de banca (T-ITS e PX4).
data/README.md	Links para download dos datasets com notas sobre licenças.

2. O Que Está Bom — Pontos Fortes do Trabalho

Aspectos que já estão sólidos e podem ser apresentados com confiança ao professor.

Ponto Forte	Por quê é sólido
Rascunho ABNT praticamente completo	7 capítulos escritos com linguagem acadêmica, citações ABNT, tabelas de resultados reais e discussão crítica. Poucos trechos [inserir...] faltando.
Dois ramos implementados e funcionando	Ramo ciber e ramo físico com pipelines completos, reproduzíveis, com normalização correta e modelos treinados.
Split temporal correto	80/20 por classe ordenado por timestamp — não usa train_test_split aleatório. Isso é um diferencial metodológico importante para defender na banca.
EarlyStopping + ModelCheckpoint	Treinamento robusto com parada antecipada e salvamento do melhor modelo por val_loss.
Baseline Random Forest	Comparação LSTM vs RF implementada e documentada nos dois ramos — mostra maturidade metodológica.
Features derivadas inteligentes (ramo físico)	r_xy, innov_norm e dv_xy são contribuições analíticas próprias que capturam a física do voo sob ataque, especialmente o GPS Spoofing.
Documentação honesta das limitações	O trabalho declara claramente: 1 voo por classe, ausência de fusão temporal calibrada, protótipo offline. Isso é o que avaliadores esperam e valorizam.
Normalização sem vazamento	MinMaxScaler e StandardScaler ajustados só no treino e aplicados ao teste — prática correta e explicitamente documentada.
Discussão da complementaridade dos ramos	O Capítulo 5 articula bem por que rede e física se complementam: ramo ciber fraco em Replay, ramo físico fraco em Ping DoS — argumento central do IDS híbrido.
Figuras salvas como PNG de alta resolução	confusion_matrix_cyber.png, learning_curves_amo_ciber.png, confusion_matrix_px4.png, learning_curves_amo_fisico.png — prontas para inserir no documento Word/LaTeX.

3. O Que Precisa Melhorar

Problemas identificados que impactam a qualidade do trabalho e podem ser apontados na banca. Ordenados por prioridade.

3.1 Problemas de Desempenho dos Modelos

Problema	Prioridade	Ação recomendada
Recall baixo de Replay (LSTM: 0,284 RF: 0,495)	Alta prioridade	Janela de 10 timesteps é curta demais para capturar o padrão definitivo do Replay (repetição de sequências). Testar janela=20 e janela=30 (código já existe, RUN_WINDOW_ABLATION=False).
F1 baixo de Ping DoS no ramo físico (LSTM: 0,245 RF: 0,600)	Alta prioridade	Normal e Ping DoS se sobrepõem nas features de posição/velocidade nos logs SITL simulados. Adicionar features de status (vehicle_status, commander_state) pode ajudar. Também declarar claramente como limitação do dataset.
LSTM inferior ao RF no ramo físico (F1-macro 0,549 vs 0,674)	Média prioridade	Causa: apenas 1 voo por classe → overfitting severo (acurácia treino 0,774 vs validação 0,215). Documentar isso na discussão, que já está escrito. Tentar LSTM com mais Dropout ou regularização L2.
Validação aleatória no ramo físico	Média prioridade	O notebook Infos_lstm_fusao_px4.ipynb usa validation_split=0,1 aleatório dentro do treino. O DOCUMENTO.md já aponta: a métrica correta é o teste temporal, não o val_accuracy oscilante durante o fit. Alterar para validação temporal contígua.

3.2 Problemas no Texto da Monografia

Problema	Prioridade	Ação recomendada
Figura 1 faltando (diagrama da arquitetura)	Alta prioridade	O rascunho tem [INSERIR FIGURA 1 — Diagrama da arquitetura do IDS híbrido]. Essa figura é essencial para o Cap. 3 e qualquer avaliador vai pedir. Pode ser feita no draw.io, PowerPoint ou matplotlib.
Figuras 4 e 5 do ramo físico faltando no rascunho	Alta prioridade	As figuras curvas de aprendizado e matriz de confusão do ramo físico já foram geradas (PNGs existem) mas os [INSERIR ...] no Cap. 4 não foram substituídos.
Trechos [inserir ...] nas referências	Alta prioridade	Referência do IEEE DataPort com 'Acesso em: [inserir data]' e citação secundária do LSTM 'inserir fonte secundária'. Preencher antes da entrega.
Tabela 1 inconsistente	Média prioridade	A distribuição de rótulos no Cap. 3 mostra Total = 33.104, mas o df tem 54.783 linhas no total. Acrescentar nota explicando que 33.104 é o subconjunto com todas as colunas válidas para o modelo.
Ausência de curvas ROC/PR	Baixa prioridade	Mencionadas como opcionais no resumo.md. Para um TCC de graduação, F1-macro e matriz de confusão já são suficientes. Adicionar se o orientador pedir.

3.3 Problemas Metodológicos Menores

Problema	Prioridade	Ação recomendada
Ablação de janela não executada	Média prioridade	<code>RUN_WINDOW_ABLATION = False</code> . O código está pronto no notebook. Executar comparação entre <code>window=10, 20, 30</code> e reportar F1-macro por janela em uma tabela simples — fortalece o argumento sobre Replay.
Estabilidade estatística (seed única)	Baixa prioridade	Toda avaliação usa <code>random_state=42</code> (uma única execução). Repetir com 3–5 seeds e reportar média $\pm$ desvio padrão é recomendado, mas pode ficar como trabalho futuro em TCC de graduação.
Matriz de confusão normalizada por linha	Baixa prioridade	A matriz atual mostra contagens absolutas. Normalizar por linha (taxa de erro por classe verdadeira) facilita a interpretação visual e é mais informativa. Uma linha de código no notebook.
Citação da topologia de rede do Dataset T-ITS	Baixa prioridade	O <code>DOCUMENTO.md</code> aponta: equipamentos exatos, como foram gerados os rótulos e posição do atacante devem vir do <code>paper/DataPort</code> . Confirmar e citar no Cap. 3.

4. O Que Está Faltando (Lacunas em Aberto)

Itens previstos nos objetivos ou mencionados no README que ainda não foram implementados. Alguns são obrigatórios para fechar o escopo; outros podem ser declarados como trabalho futuro.

O que falta	Classificação	O que fazer
MAVLink Sequence Dataset	Obrigatório citar	Previsto no README como segunda fonte de dados principal. Não há notebook nem análise. Opções: (a) analisar e usar; (b) declarar explicitamente no texto que foi previsto mas ficou fora do escopo por limitação de tempo — com justificativa.
Figura 1 — Diagrama da arquitetura do IDS	Obrigatório	Sem essa figura, o Cap. 3 fica incompleto. É um diagrama simples mostrando os dois ramos (ciber: T-ITS → LSTM/RF; físico: PX4 → fusão → LSTM/RF) e a camada de decisão futura. Pode ser feito em draw.io.
Inserção das figuras PNGs no rascunho ABNT	Obrigatório	Os quatro PNGs gerados pelos notebooks (curvas e matrizes dos dois ramos) precisam ser inseridos no documento Word/LaTeX nos marcadores [INSERIR ...] do Cap. 4.
Datas de acesso nas referências	Obrigatório ABNT	Referência do IEEE DataPort exige 'Acesso em: DD mês. AAAA'. Preencher com a data real em que o dataset foi acessado.
Ablação de janela temporal (window=10/20/30)	Recomendado	Código pronto no notebook (RUN_WINDOW_ABLATION = True). Executar e reportar em nova tabela no Cap. 4. Fortalece muito a argumentação sobre o Replay.
Análise do MAVLink Sequence Dataset	Recomendado	Mesmo que não seja incluída no modelo final, uma análise exploratória curta justifica por que esse dataset não foi usado (ou como seria usado em trabalho futuro).
Fusão decisória dos dois ramos	Trabalho futuro	Corretamente descrito como trabalho futuro no rascunho. Não é obrigatório implementar — apenas declarar claramente as condições necessárias (datasets com coleta simultânea).
IDS em tempo quase real	Trabalho futuro	Medição de latência de inferência e pipeline de ingestão contínua. Corretamente descrito como trabalho futuro — não é necessário implementar para o TCC.

5. Plano de Ação Priorizado

Lista de tarefas ordenadas por urgência. As tarefas obrigatórias precisam ser concluídas antes da entrega. As recomendadas fortalecem o trabalho. As opcionais ficam para trabalhos futuros.

Tarefas Obrigatórias (antes da entrega)

#	Tarefa	Como fazer
1	Criar Figura 1 — Diagrama da arquitetura do IDS híbrido	draw.io / PowerPoint / matplotlib — 2 caixas (ramo ciber + ramo físico) + setas + camada de decisão futura.
2	Inserir as 4 figuras PNG no rascunho ABNT	Substituir os 4 marcadores [INSERIR ...] no Cap. 4 pelos PNGs gerados pelos notebooks.
3	Preencher datas de acesso nas referências	Completar 'Acesso em: [inserir data]' na referência do IEEE DataPort no Cap. 7.
4	Resolver inconsistência da Tabela 1	Adicionar nota explicando que 33.104 é o subconjunto válido para o modelo, dentro dos 54.783 totais do CSV.
5	Posicionar o MAVLink Sequence Dataset no texto	Adicionar parágrafo no Cap. 3 ou 6 explicando por que não foi utilizado (escopo) e como seria usado em trabalho futuro.
6	Corrigir validação aleatória no ramo físico	No notebook Infos_Istm_fusao_px4.ipynb: trocar validation_split=0,1 por validação contígua nos últimos 10% do treino concatenado.

Tarefas Recomendadas (fortalecem o trabalho)

#	Tarefa	Como fazer
7	Executar ablação de janela temporal	No notebook ramo ciber, alterar RUN_WINDOW_ABLATION = True. Comparar F1-macro para window=10, 20, 30. Adicionar tabela no Cap. 4.
8	Adicionar matriz de confusão normalizada	Em ambos os notebooks: adicionar confusion_matrix(normalize='true') para mostrar taxas de erro por classe, não contagens brutas.
9	Adicionar features extras no ramo físico	Tentar vehicle_status_0.csv ou commander_state_0.csv para ajudar a separar Ping DoS de Normal.
10	Verificar citação da topologia do Dataset T-ITS	Confirmar no paper de Hassler et al. (2024) o drone utilizado, firmware e como os rótulos foram gerados.

Tarefas Opcionais (trabalhos futuros — não obrigatórias)

#	Tarefa	Como fazer
11	Repetir treino LSTM com múltiplas seeds	3–5 seeds, reportar F1-macro médio $\pm$ desvio padrão.
12	Curvas ROC/PR multiclasse	one-vs-rest com sklearn.metrics.roc_auc_score — útil se o orientador pedir.

#	Tarefa	Como fazer
13	Análise exploratória do MAVLink Sequence Dataset	Mesmo que não entre no modelo, mostrar consciência sobre a fonte.
14	Fusão decisória dos dois ramos	Combinação das probabilidades de saída dos dois detectores — condicionada a datasets com coleta simultânea.

6. Análise Crítica dos Resultados Atuais

6.1 Ramo Ciber — Resultados Consolidados

Classe	LSTM Precision	LSTM Recall	LSTM F1	RF Precision	RF Recall	RF F1
Benign	0,764	0,978	0,858	0,759	0,979	0,855
DoS attack	0,590	0,829	0,690	0,608	0,574	0,591
Replay	0,733	0,284	0,409	0,599	0,495	0,542
Macro avg	0,696	0,697	0,652	0,655	0,683	0,663

Interpretação: Benign bem detectado pelos dois modelos. DoS com recall alto na LSTM (0,829) mas precário no RF (0,574). Replay é o grande problema: recall 0,284 na LSTM. Causa estrutural — janela de 10 timesteps é curta demais para identificar repetição de sequências. RF ligeiramente melhor em F1-macro.

6.2 Ramo Físico — Resultados Consolidados

Classe	LSTM Precision	LSTM Recall	LSTM F1	RF Precision	RF Recall	RF F1
Normal	0,862	0,822	0,841	0,851	0,800	0,825
GPS Spoofing	0,451	0,744	0,561	0,529	0,684	0,597
Ping DoS	0,461	0,166	0,245	0,699	0,526	0,600
Macro avg	0,591	0,578	0,549	0,693	0,670	0,674

Interpretação: RF supera LSTM significativamente neste ramo (F1-macro 0,674 vs 0,549). Causa principal: overfitting severo da LSTM com apenas 1 voo por classe. GPS Spoofing moderadamente detectado pelos dois (r_{xy} é o principal discriminador). Ping DoS é a classe mais fraca — Normal e Ping DoS se sobrepõem nas features de posição/velocidade nos logs SITL.

6.3 Argumento Central que Sustenta o IDS Híbrido

Os resultados dos dois ramos, lidos em conjunto, demonstram a complementaridade que justifica a arquitetura híbrida:

- No ramo ciber, **DoS** é bem detectado (LSTM recall 0,829) mas **Replay é difícil** (LSTM recall 0,284). Replay imita estatisticamente o tráfego legítimo — só seria distinguível com janelas maiores ou análise de conteúdo MAVLink.
- No ramo físico, **GPS Spoofing** é o mais detectável (LSTM recall 0,744, RF recall 0,684) graças à feature r_{xy} (deriva horizontal de 10^1 m no Spoofing vs 10^2 m no Normal). **Ping DoS** é ambíguo nos logs de telemetria simulada.
- A complementaridade é real: um ataque invisível no tráfego de rede pode deixar rastro na telemetria física, e vice-versa. Isso é o argumento central do TCC e está bem escrito no Cap. 5 do rascunho.